1.最基本的抓站

```
import urllib2
content = urllib2.urlopen('http://XXXX').read()
```

-

2.使用代理服务器

这在某些情况下比较有用，比如 IP 被封了，或者比如 IP 访问的次数受到限制等等。

```
import urllib2
proxy_support = urllib2.ProxyHandler({'http':'http://XX.XX.XX.XX:XXXX'})
opener = urllib2.build_opener(proxy_support, urllib2.HTTPHandler)
urllib2.install_opener(opener)
content = urllib2.urlopen('http://XXXX').read()
```

-

3.需要登录的情况

登录的情况比较麻烦我把问题拆分一下：

-

3.1 cookie 的处理

```
import urllib2, cookielib
cookie_support= urllib2.HTTPCookieProcessor(cookielib.CookieJar())
opener = urllib2.build_opener(cookie_support, urllib2.HTTPHandler)
urllib2.install_opener(opener)
content = urllib2.urlopen('http://XXXX').read()
```

是的没错，如果想同时用代理和 cookie，那就加入 proxy_support 然后 operner 改为

```
opener = urllib2.build_opener(proxy_support, cookie_support, urllib2.HTTPHandler)
```

-

3.2 表单的处理

登录必要填表，表单怎么填？首先利用工具截取所要填表的内容

比如我一般用 firefox+httpfox 插件来看看自己到底发送了些什么包

这个我就举个例子好了，以 verycd 为例，先找到自己发的 POST 请求，以及 POST 表单项：

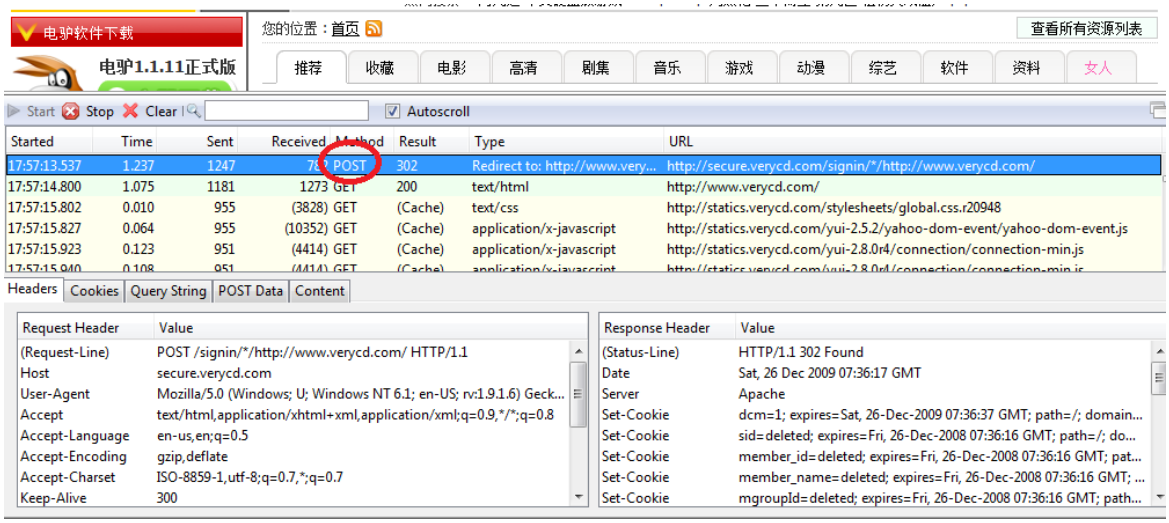

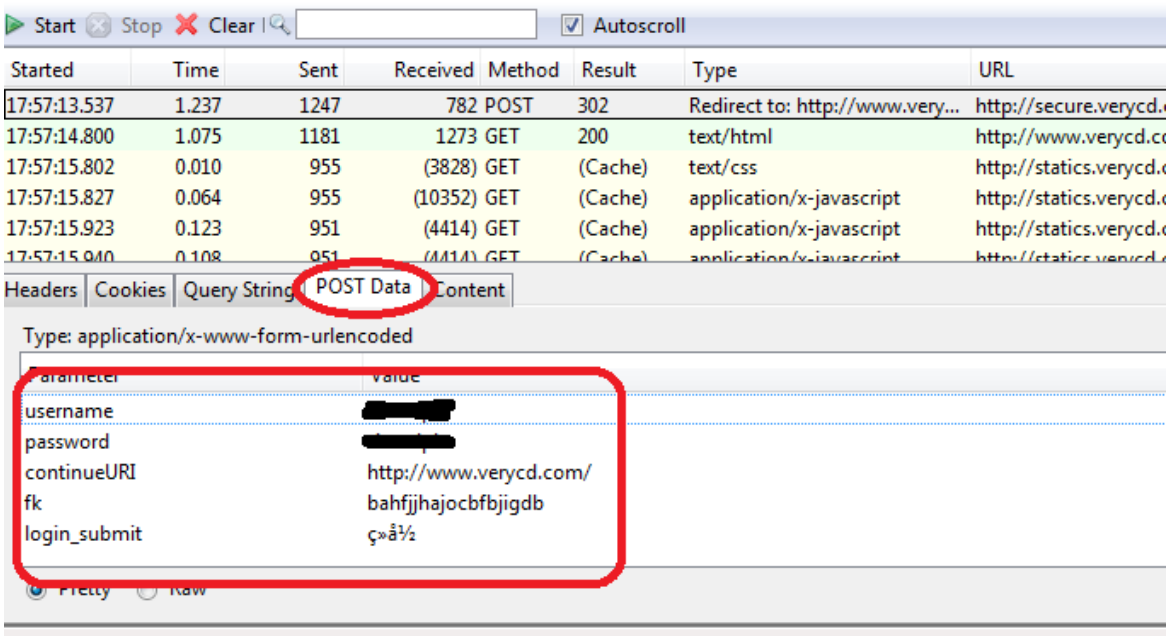

-

可以看到 verycd 的话需要填 username,password,continueURI,fk,login_submit 这几项，其中 fk 是随机生 成的（其实不太随机，看上去像是把 epoch 时间经过简单的编码生成的），需要从网页获取，也就是说得先访问一次网页，用正则表达式等工具截取返回数据中 的 fk 项。continueURI 顾名思义可以随便写，login_submit 是固定的，这从源码可以看出。还有 username，password 那 就很显然了。

-

好的，有了要填写的数据，我们就要生成 postdata

import urllib

```
postdata=urllib.urlencode({
    'username':'XXXXX',
    'password':'XXXXX',
    'continueURI':'http://www.verycd.com/',
    'fk':fk,
    'login_submit':'登录'
})
```

-

然后生成 http 请求，再发送请求：

```
req = urllib2.Request(
    url = 'http://secure.verycd.com/signin/*/http://www.verycd.com/',
    data = postdata
)
result = urllib2.urlopen(req).read()
```

-

3.3 伪装成浏览器访问

某些网站反感爬虫的到访，于是对爬虫一律拒绝请求

这时候我们需要伪装成浏览器，这可以通过修改 http 包中的 header 来实现

```
#…
headers = {
    'User-Agent':'Mozilla/5.0 (Windows; U; Windows NT 6.1; en-US; rv:1.9.1.6)
Gecko/20091201 Firefox/3.5.6'
}
req = urllib2.Request(
    url = 'http://secure.verycd.com/signin/*/http://www.verycd.com/',
    data = postdata,
    headers = headers
)
#...
```

-

3.4 反”反盗链”

某些站点有所谓的反盗链设置，其实说穿了很简单，就是检查你发送请求的 header 里面，referer 站点是不是他自己，所以我们只需要像 3.3 一样， 把 headers 的 referer 改成该网站即可，以黑幕著称地 cnbeta 为例：

```
#...
```

```
headers = {
    'Referer':'http://www.cnbeta.com/articles'
}
#...
```

headers 是一个 dict 数据结构，你可以放入任何想要的 header，来做一些伪装。例如，有些自作聪明的网站总喜欢窥人隐私，别人通过代理 访问，他偏偏要读取 header 中的 X-Forwarded-For 来看看人家的真实 IP，没话说，那就直接把 X-Forwarde-For 改了吧，可以 改成随便什么好玩的东东来欺负欺负他，呵呵。

-

3.5 终极绝招

有时候即使做了 3.1-3.4，访问还是会被据，那么没办法，老老实实把 httpfox 中看到的 headers 全都写上，那一般也就行了。

再不行，那就只能用终极绝招了，selenium 直 接控制浏览器来进行访问，只要浏览器可以做到的，那么它也可以做到。类似的还有 pamie，watir，等等等等。

-

4.多线程并发抓取

单线程太慢的话，就需要多线程了，这里给个简单的线程池模板

这个程序只是简单地打印了 1-10，但是可以看出是并发地。

```
from threading import Thread
from Queue import Queue
from time import sleep
#q 是任务队列
#NUM 是并发线程总数
#JOBS 是有多少任务
q = Queue()
NUM = 2
JOBS = 10
#具体的处理函数，负责处理单个任务
def do_somthing_using(arguments):
    print arguments
#这个是工作进程，负责不断从队列取数据并处理
def working():
    while True:
        arguments = q.get()
        do_somthing_using(arguments)
```

```
        sleep(1)
        q.task_done()
#fork NUM 个线程等待队列
for i in range(NUM):
    t = Thread(target=working)
    t.setDaemon(True)
    t.start()
#把 JOBS 排入队列
for i in range(JOBS):
    q.put(i)
#等待所有 JOBS 完成
q.join()
```

5.验证码的处理

碰到验证码咋办？这里分两种情况处理：

-

1.google 那种验证码，凉拌

-

2.简单的验证码：字符个数有限，只使用了简单的平移或旋转加噪音而没有扭曲的，这种还是有可能可以处理的，一般思路是旋转的转回来，噪音去掉，然后划分 单个字符，划分好了以后再通过特征提取的方法(例如 PCA) 降维并生成特征库，然后把验证码和特征库进行比较。这个比较复杂，一篇博文是说不完的，这里就不展开了，具体做法请弄本相关教科书好好研究一下。

-

3.事实上有些验证码还是很弱的，这里就不点名了，反正我通过 2 的方法提取过准确度非常高的验证码，所以 2 事实上是可行的。

-

6.总结

基本上我遇到过的所有情况，用以上方法都顺利解决了，不太清楚还有没有其他漏掉的情况，所以本文到这里就完成了，以后要是碰上其他情况，再补充相关方法好 了：）